

zmlab1_zadania_i_odpowiedzi

November 12, 2023

1 Błędy i arytmetyka zmiennopozycyjna

Całość kodu można znaleźć w formie online pod linkiem <https://github.com/KsawerySmoczynski/elementy-metod-numerycznych>. Jest on również dostępny w google collab

```
[1]: # Żeby odpalić notebook na google colab będziemy musieli zainstalować potrzebne ↵
    ↪ pakiety
import subprocess
import sys
import os

REQUIRED_PACKAGES = ["numpy", "matplotlib", "sympy"]
RUN_IN_COLAB = "COLAB_JUPYTER_IP" in os.environ

def install(packages):
    subprocess.check_call([sys.executable, "-m", "pip", "install", *packages])

if RUN_IN_COLAB:
    install(REQUIRED_PACKAGES)
```

1.1 Zadania

1.1.1 Zadanie1

Oblicz: $*(0.1+0.2)+0.3$ oraz $0.1+(0.2+0.3)* (0.1*0.6)*0.7$ oraz $0.1*(0.6*0.7), * 0.1*(0.7-0.6)$ oraz $0.1*0.7-0.1*0.6$

Porównaj otrzymane wyniki.

```
[2]: a = (.1 + .2) + .3
    b = .1 + (.2 +.3)
    a == b, a, b
```

```
[2]: (False, 0.6000000000000001, 0.6)
```

```
[3]: a = (.1 * .6) * .7
    b = .1 + (.6 * .7)
    a == b, a, b
```

[3]: (False, 0.041999999999999996, 0.52)

```
[4]: a = .1 * (.7 - .6)
      b = .1 * .7 - .1 * .6
      a == b, a, b
```

[4]: (False, 0.009999999999999998, 0.009999999999999995)

1.1.2 Zadanie 2

Niech $a = 1 + \epsilon$, $b = 1 + \frac{\epsilon}{2}$.

Które z tych liczb są równe 1 w arytmetyce zmiennopozycyjnej?

Czy liczby $a - 1$ i $b - 1$ są równe 0? Czy $\frac{\epsilon}{2} = 0$?

Najpierw uzyskajmy epsilon maszynowy:

```
[5]: def machineEpsilon(func=float):
      machine_epsilon = func(1)
      ONE = func(1)
      while ONE+machine_epsilon != ONE:
          machine_epsilon_last = machine_epsilon
          machine_epsilon = func(machine_epsilon) / func(2)
      return machine_epsilon_last

      machineEpsilon(float)
```

[5]: 2.220446049250313e-16

```
[6]: import sys
      sys.float_info.epsilon
```

[6]: 2.220446049250313e-16

Jak widać uzyskany przez nas epsilon jest równy temu z informacji systemowej

```
[7]: import numpy as np

      np.finfo(np.float64).eps
```

[7]: 2.220446049250313e-16

Który jest równy temu zapewnianemu przez pakiet do obliczeń numerycznych na wektorach - numpy

```
[8]: machine_eps = np.finfo(np.float64).eps

      a = 1. + machine_eps
      b = 1. + machine_eps / 2
```

```
[9]: a == 1, b == 1
```

[9]: (False, True)

Odpowiedź: Tylko druga liczba (b) jest równa 1 w arytmetyce zmiennopozycyjnej.

```
[10]: a - 1 == 0, b - 1 == 0
```

[10]: (False, True)

Odpowiedź: Odpowiednio $a - 1 \neq 0$ oraz $b - 1 = 0$

```
[11]: machine_eps / 2 == 0
```

[11]: False

Odpowiedź: Nie ponieważ epsilon maszynowy nie jest najmniejszą dodatnią reprezentowalną liczbą w systemie 32 bitowym, tylko różnicą między najbliższą reprezentowalną liczbą względem jedynki, a jedynką.

1.1.3 Zadanie 3

Napisz skrypt zliczający sumę argumentów 0.1 do momentu, gdy otrzymana wartość wyniesie 2. Wykorzystaj pętlę while i dwa różne warunki stopu:

1. *while suma <> 2,*
2. *\$ while ; abs(suma-2)>0.001\$.*

Czy w obu przypadkach otrzymamy to samo?

```
[15]: # Uwaga pętla nieskończona
suma_1 = .1
while suma_1 != 2:
    suma_1 += .1
```

```
[12]: suma_2 = .1
while abs(suma_2 - 2) > .001:
    suma_2 += .1
suma_2
```

[12]: 2.0000000000000004

Odpowiedź: Nie otrzymamy tego samego ponieważ `suma_1` nigdy nie będzie równać się dokładnie 2 w związku z czym pierwsza pętla nigdy nie zakończy swojego działania.

1.1.4 Zadanie 4

Zdefiniujmy ciąg całek wzorem

$$y_n = \int_0^1 \frac{x^n}{x+5} dx$$

Ciąg ten spełnia zależność rekurencyjną $y_n + 5y_{n-1} = \frac{1}{n}$. Korzystając z tej zależności chcemy obliczyć wartości poszczególnych całek.

1. Napisz skrypt, który oblicza przybliżone wartości całek y_1, \dots, y_8 , wykorzystując wzór rekurencyjny $y_n = \frac{1}{n} - 5y_{n-1}$ oraz początkowe przybliżenie całki $y_0 \approx 0.182$.
2. Napisz skrypt, który oblicza przybliżone wartości całek y_7, \dots, y_0 , wykorzystując wzór rekurencyjny $y_{n-1} = \frac{1}{5n} - \frac{1}{5}y_n$ oraz początkowe przybliżenie całki $y_8 \approx 0.019$.
3. Porównaj otrzymane w powyższych punktach wyniki i spróbuj wyjaśnić powstałe różnice.

1.

```
[13]: # Sekwencyjna wersja
y_0 = 0.128
y = [y_0]
n = 9
for i in range(1, n):
    n_i = i+1
    y_n = 1/n_i - 5*y[n_i-2] # listy są indeksowane od 0 dlatego odejmujemy 2,
    ↪a nie 1
    y.append(y_n)
y
```

```
[13]: [0.128,
      -0.14,
      1.0333333333333334,
      -4.916666666666667,
      24.783333333333335,
      -123.75,
      618.8928571428571,
      -3094.3392857142853,
      15471.807539682539]
```

```
[14]: # Wersja rekurencyjna
from functools import lru_cache # Żeby nie przeliczać od nowa wartości dla tych
    ↪samych wyrazów użyjemy cacheowania
# w ten sposób po przeliczeniu dla n-tego wyrazu zapamiętujemy jego wartości i
    ↪odczytujemy z pamięci dla n+1 wyrazu
# nie wpływa to na wyniki tylko czas wykonywania algorytmu

@lru_cache
def y_n(n):
    if n == 1:
        return 0.128
    else:
        return 1/n - 5*y_n(n-1)
```

```
[15]: n = 9

y = []
for i in range(0,n):
    n_i = i+1
```

```
y.append(y_n(n_i))
y
```

```
[15]: [0.128,
      -0.14,
      1.0333333333333334,
      -4.916666666666667,
      24.783333333333335,
      -123.75,
      618.8928571428571,
      -3094.3392857142853,
      15471.807539682539]
```

2.

```
[16]: @lru_cache
def y_n(n):
    if n == 9:
        return 0.019
    elif n < 9:
        return 1/(5*n) - (1/5 * y_n(n+1))
    else:
        raise NotImplementedError("Algorithm defined up to 9th term")
```

```
[17]: y = []
      n = 9
      while n >= 1:
          y.append(y_n(n))
          n -= 1

      list(reversed(y))
```

```
[17]: [0.1823215572114286,
      0.08839221394285715,
      0.05803893028571428,
      0.04313868190476191,
      0.034306590476190474,
      0.028467047619047618,
      0.02433142857142857,
      0.0212,
      0.019]
```

3. Odpowiedź a - niestabilne numerycznie rozwiązanie - każdy następny wyraz multiplikuje błąd uzyskany w poprzednim

b - stabilne numerycznie rozwiązanie - każdy poprzedni wyraz powoduje dzielenie błędu

1.1.5 Zadanie 5.

Dla $x = 8^{-1}, 8^{-2}, \dots, 8^{-10}$ oblicz wartości funkcji: 1. $f(x) = \sqrt{x^2 + 1} - 1$, 2. $g(x) = \frac{x^2}{\sqrt{x^2 + 1} - 1}$.

Porównaj otrzymane wartości.

```
[18]: x = 1 / (8 ** np.arange(1,11))
      x
```

```
[18]: array([1.25000000e-01, 1.56250000e-02, 1.95312500e-03, 2.44140625e-04,
        3.05175781e-05, 3.81469727e-06, 4.76837158e-07, 5.96046448e-08,
        7.45058060e-09, 9.31322575e-10])
```

```
[19]: # 1.
      f = lambda x: np.sqrt(x**2 + 1) - 1
      f(x)
```

```
[19]: array([7.78221854e-03, 1.22062863e-04, 1.90734681e-06, 2.98023219e-08,
        4.65661287e-10, 7.27595761e-12, 1.13686838e-13, 1.77635684e-15,
        0.00000000e+00, 0.00000000e+00])
```

```
[20]: # 2.
      g = lambda x: x**2 / (np.sqrt(x**2 + 1) - 1)
      g(x)
```

```
/var/folders/j_/gy0508_n2w36wpr12gx3tz2m0000gn/T/ipykernel_80666/3292143112.py:2
: RuntimeWarning: divide by zero encountered in divide
  g = lambda x: x**2 / (np.sqrt(x**2 + 1) - 1)
```

```
[20]: array([2.00778222, 2.00012206, 2.00000191, 2.00000003, 2.
        2.
        , 2.
        , 2.
        ,
        inf,
        inf])
```

1.1.6 Zadanie 5

Rozważmy funkcję $f(x) = \sin(x)$. Pochodną tej funkcji możemy przybliżyć za pomocą ilorazu różnicowego:

$$f'(x) \approx \frac{\sin(x+h) - \sin(x)}{h}$$

dla małych wartości h . Dla $h = 10^{-n}$ ($n = 1, \dots, 16$) i $x = 1$ wyznacz błąd tego przybliżenia.

Dla jakiej wartości h otrzymane przybliżenie jest najlepsze?

Zilustruj wyniki na wykresie, na którym wartości błędów będą prezentowane w skali logarytmicznej.

```
[21]: x = 1
      h = np.array([float(f"1e-{i}") for i in range(1, 17)])
```

```
[22]: approx_f_prime = lambda x, h: (np.sin(x+h) - np.sin(x)) / h
      approx_f_prime(x, h)
```

```
[22]: array([0.49736375, 0.53608598, 0.53988148, 0.54026023, 0.5402981 ,
           0.54030189, 0.54030226, 0.54030229, 0.54030236, 0.54030225,
           0.54030114, 0.54034555, 0.53956839, 0.54400928, 0.55511151,
           0.          ])
```

```
[23]: f_prime = np.cos
      f_prime(x)
```

```
[23]: 0.5403023058681398
```

```
[24]: errors = np.abs(f_prime(x) - approx_f_prime(x, h))
      errors
```


```
[24]: array([4.29385533e-02, 4.21632486e-03, 4.20825508e-04, 4.20744495e-05,
           4.20736228e-06, 4.20746809e-07, 4.18276911e-08, 1.40721155e-08,
           5.25412660e-08, 5.84810365e-08, 1.16870406e-06, 4.32402169e-05,
           7.33915900e-04, 3.70697620e-03, 1.48092064e-02, 5.40302306e-01])
```

```
[25]: h
```

```
[25]: array([1.e-01, 1.e-02, 1.e-03, 1.e-04, 1.e-05, 1.e-06, 1.e-07, 1.e-08,
           1.e-09, 1.e-10, 1.e-11, 1.e-12, 1.e-13, 1.e-14, 1.e-15, 1.e-16])
```

```
[26]: import matplotlib.pyplot as plt

fig, ax = plt.subplots(figsize=(9, 4))
ax.plot(h, errors, color="red")
ax.set_xlabel("h")
ax.set_ylabel("Błąd przybliżenia")
ax.set_xscale("log")
ax.set_yscale("log")
ax.set_xticks(h)
plt.show()
```



Odpowiedź: Jak widać najlepszy błąd przybliżenia uzyskujemy dla $h = 10^{-8}$

1.2 Zadanie 6 (* 2 pkt)


Niech $f(x) = \cos(x) - 1 = -2\sin^2(\frac{x}{2})$. Oblicz wartość podanej funkcji stosując oba podane wzory dla 1000 wartości x równomiernie rozłożonych w $(-10^{-7}, 10^{-7})$ i zilustruj otrzymane wyniki na wykresie.

Który wzór wydaje się lepszy? Spróbuj wyjaśnić, dlaczego tak jest.

Oba wykresy powinny być narysowane w jednym oknie i rozróżnialne (poprzez zastosowanie różnych kolorów lub stylów linii). Ponadto, proszę umieścić przy wykresach legendę.

```
[27]: x = np.linspace(-1e-7, 1e-7, int(1e3))
      f_1 = lambda x: np.cos(x) - 1
      f_2 = lambda x: -2 * np.sin(x/2)**2
```

```
[28]: fig, ax = plt.subplots()
      ax.plot(x, f_1(x), color="red", alpha=0.8, label=r"$f(x)=\cos(x)-1$")
      ax.plot(x, f_2(x), color="blue", alpha=0.8,
              label=r"$f(x)=-2\sin^2(\frac{x}{2})$")
      plt.legend(title='Parameter where:')
      plt.show()
```

1.2.1 Zadanie 7 (* 2 pkt)

Rozważmy wielomian $w(x) = (x - 1)^4 = x^4 - 4x^3 + 6x^2 - 4x + 1$.

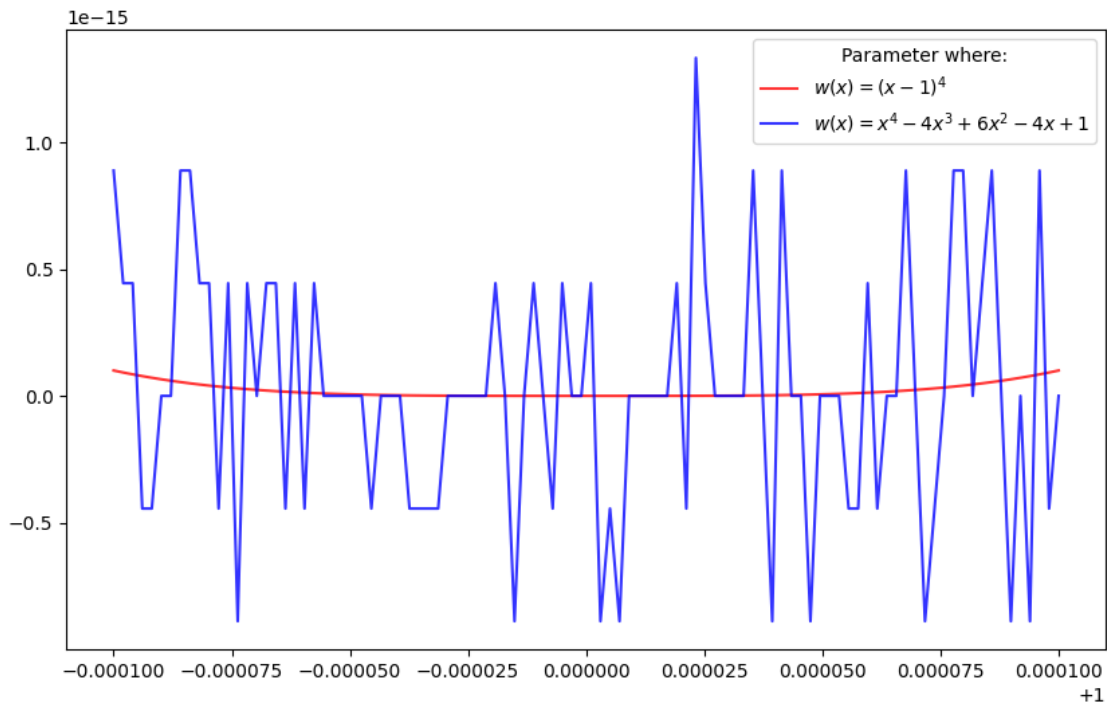
Oblicz stosując oba podane wzory wartość tego wielomianu dla 100 wartości x równomiernie rozłożonych w przedziale $(0.9999, 1.0001)$ i zilustruj otrzymane wyniki na wykresie.

Który wzór wydaje się lepszy? Spróbuj wyjaśnić, dlaczego tak jest.

Oba wykresy powinny być narysowane w jednym oknie i rozróżnialne (poprzez zastosowanie różnych kolorów lub stylów linii). Ponadto, proszę umieścić przy wykresach legendę.

```
[29]: x = np.linspace(0.9999, 1.0001, 100)
      w_1 = lambda x: (x-1)**4
      w_2 = lambda x: x**4 - 4*x**3 + 6*x**2 - 4*x + 1
```

```
[30]: fig, ax = plt.subplots(figsize=(10,6))
      ax.plot(x, w_1(x), color="red", alpha=0.8, label=r"$w(x)=(x-1)^4$")
      ax.plot(x, w_2(x), color="blue", alpha=0.8, label=r"$w(x)=x^4-4x^3+6x^2-4x+1$")
      plt.legend(title='Parameter where:')
      plt.show()
```



Odpowiedź: Przy postaci ogólnej wielomianu dokonujemy wielu operacji dodawania/odejmowania bliskich sobie liczb co powoduje narastanie błędu poprzez kolejne utraty liczb znaczących, natomiast w postaci iloczynowej odejmowania dokonujemy tylko raz co powoduje relatywnie mniejszy błąd, stąd wzór w postaci iloczynowej zdaje się być lepszy do obliczania w postaci zmiennoprzecinkowej.

2 Algorytm Hornera

Zauważmy, że wielomian o naturalnej postaci:

$$w(x) = \sum_{i=0}^n a_i x^i$$

można także zapisać jako:

$$w(x) = (\dots((a_n x + a_{n-1})x + a_{n-2})x + \dots + a_1)x + a_0.$$

Z postaci tej wynika sposób obliczania wartości wielomianu w punkcie zwany algorytmem Hornera. Załóżmy, że chcemy obliczyć wartość wielomianu $w(x)$ w punkcie x_0 . Definiujemy:

$$\begin{aligned} w_n &= a_n, \\ w_i &= w_{i+1}x_0 + a_i, \text{ dla } i = n-1, n-2, \dots, 0 \end{aligned}$$

Wtedy $w(x_0) = w_0$. Obliczając wartość wielomianu w punkcie w ten sposób ograniczamy liczbę mnożeń. Stosując algorytm Hornera możemy także obliczyć wynik dzielenia wielomianu $w(x)$ przez dwumian $x - c$. Jeśli bowiem

$$\sum_{i=0}^n a_i x^i = \left(\sum_{i=0}^{n-1} b_{i+1} x^i \right) (x - c) + b_0,$$

to porównując współczynniki przy odpowiednich potęgach otrzymujemy zależność $a_i = b_i - b_{i+1}c$ dla $i = 0, \dots, n-1$ i $a_n = b_n$. Oznacza to, że $b_i = w_i$ dla $i = 0, \dots, n$.

Kolejnym zastosowaniem algorytmu Hornera jest obliczanie wartości pochodnych znormalizowanych w punkcie x_0 , tzn. wartości:

$$\frac{w^{(j)}(x_0)}{j!} \text{ dla } j = 0, 1, \dots, n.$$

Zapiszmy wielomian $w(x)$ w postaci:

$$w(x) = (x - x_0)^j v(x) + r(x),$$

gdzie $r(x)$ jest wielomianem o stopniu mniejszym od j . Różniczkując to wyrażenie j razy i obliczając jego wartość w punkcie x_0 otrzymujemy równość:

$$w^{(j)}(x_0) = j!v(x_0).$$

Zatem chcąc obliczyć wartość j -tej pochodnej znormalizowanej wielomianu wystarczy zastosować algorytm Hornera j razy, żeby podzielić kolejno otrzymywane ilorazy przez $x - x_0$, a następnie obliczyć wartość otrzymanego wielomianu w punkcie x_0 .

Ostatnim omawianym zastosowaniem algorytmu Hornera będzie zamiana liczby zapisanej w systemie pozycyjnym o podstawie p ($p \neq 10$) na zapis w systemie dziesiętnym. Rozważmy liczbę zapisaną w systemie pozycyjnym o podstawie p :

$$c_n c_{n-1} \dots c_1 c_0 \text{ (} p \text{)} = c_n p^n + c_{n-1} p^{n-1} + \dots + c_1 p + c_0.$$

Zatem chcąc obliczyć wartość tej liczby w systemie dziesiętnym wystarczy obliczyć wartość wielomianu $w(x) = \sum_{i=0}^n c_i x^i$ w punkcie p .

Wielomian możemy też zapisać w tzw. postaci Newtona:

$$w(x) = \sum_{k=0}^n b_k \prod_{j=0}^{k-1} (x - x_j) = b_0 + b_1(x - x_0) + b_2(x - x_0)(x - x_1) + \dots + b_n(x - x_0) \cdot \dots \cdot (x - x_{n-1})$$

Mając dany wielomian w tej postaci możemy w łatwy sposób obliczyć jego wartość w punkcie s korzystając z uogólnionego schematu Hornera:

$$\begin{aligned} p_n &= b_n \\ p_i &= p_{i+1}(s - x_i) + b_i, \text{ dla } i = n-1, n-2, \dots, 0 \end{aligned}$$

[31]: `from numpy.polynomial import polynomial as P`

2.0.1 Zadanie 1

Stosując polecenie `horner` (w numpy `np.polynomial.polynomial.polyval`) oblicz wartość wielomianu $w(x)$ w punkcie x_0 dla: 1. $w(x) = x^3 - 2x^2 + 3x - 4$, $x_0 = 1$, 2. $w(x) = 8x^3 + 5x^2 + 3x + 1$, $x_0 = -3$.

```
[32]: # 1.  
x0 = 1  
c = np.array([-4, 3, -2, 1])  
P.polyval(x0, c)
```

[32]: -2.0

```
[33]: # 2.  
x0 = -3  
c = np.array([1, 3, 5, 8])  
P.polyval(x0, c)
```

[33]: -179.0

2.0.2 Zadanie 2.

Stosując polecenie `pdiv` (w numpy `np.polynomial.polynomial.polydiv`) wyznacz wielomian będący wynikiem dzielenia wielomianu $w(x)$ przez dwumian $d(x)$: 1. $w(x) = 2x^3 + 5x^2 - 4x + 11$, $d(x) = x - 2$, 2. $w(x) = x^4 - 9x^2 + 3x - 5$, $d(x) = x + 7$.

```
[34]: # 1.  
w = (11, -4, 5, 2)  
d = (-2, 1)  
q, r = P.polydiv(w, d)  
q, r
```

[34]: (array([14., 9., 2.]), array([39.]))

1. $q(x) = 2x^2 + 9x + 14$, $r(x) = 39$

```
[35]: # 2.  
w = (-5, 3, -9, 1)  
d = (7, 1)  
q, r = P.polydiv(w, d)  
q, r
```

[35]: (array([115., -16., 1.]), array([-810.]))

2. $q(x) = x^2 - 16x + 115$, $r(x) = x + 7$

2.0.3 Zadanie 3.

Używając poleceń `horner` i `pdiv` (w numpy `np.polynomial.polynomial.polyval` i `np.polynomial.polynomial.polydiv`), znajdź wszystkie pochodne znormalizowane wielomianu $w(x)$ w punkcie x_0 : 1. $w(x) = x^3 + 2x^2 + 4x + 8$, $x_0 = -2$, 2. $w(x) = x^4 - x^3 + 3x - 1$, $x_0 = 2$

```
[36]: # 1.  
x_0 = -2  
w = (8, 4, 2, 1)
```

```

ds = [
    (-x_0, 1),
    (4, 4, 1), # (x-x0)^2
    (8, 12, 6, 1), # (x-x0)^3
]
polynomials = [w]
for d in ds:
    v, _ = P.polydiv(w, d)
    polynomials.append(v)

```

```
[37]: import math
```

```

derivative = lambda v, j, x_0: math.factorial(j)*P.polyval(x_0, v)
normalized_derivative = lambda v, x_0: P.polyval(x_0, v)

```

```

[39]: for derivative_order, v in enumerate(polynomials):
        print(f"Derivative value at x_0 = {x_0} of order {derivative_order} equals_
        ↳{derivative(v, derivative_order, x_0)}, normalized derivative equals_
        ↳{normalized_derivative(v, x_0)}")
    print(f"(Normalized) Derivatives of order higher than 3 are equal to 0")

```

Derivative value at x_0 = -2 of order 0 equals 0.0, normalized derivative equals 0.0

Derivative value at x_0 = -2 of order 1 equals 8.0, normalized derivative equals 8.0

Derivative value at x_0 = -2 of order 2 equals -8.0, normalized derivative equals -4.0

Derivative value at x_0 = -2 of order 3 equals 6.0, normalized derivative equals 1.0

(Normalized) Derivatives of order higher than 3 are equal to 0

```

[40]: # Lets find derivatives analytically
import sympy as sp

x = sp.symbols('x')
w = x**3 + 2*x**2 + 4*x + 8
w_1 = w.diff(x)
w_1

```

```
[40]: 3x2 + 4x + 4
```

```
[41]: w_1.subs({x: x_0})
```

```
[41]: 8
```

```

[42]: w_2 = w.diff(x, 2)
w_2

```

```
[42]: 2 · (3x + 2)
```

```
[43]: w_2.subs({x: x_0})
```

```
[43]: -8
```

```
[44]: w_3 = w.diff(x, 3)
      w_3
```

```
[44]: 6
```

```
[45]: w_3.subs({x: x_0})
```

```
[45]: 6
```

Wygląda na to, że policzyliśmy poprawnie!

```
[46]: # 2.
      x_0 = 2
      w = (-1, 3, 0, -1, 1)
      ds = [
          (-x_0, 1),
          (4, -4, 1), # (x-x0)^2
          (-8, 12, -6, 1), # (x-x0)^3
          (16, -32, 24, -8, 1), # (x-x0)^4
      ]
      polynomials = [w]
      for d in ds:
          v, _ = P.polydiv(w, d)
          polynomials.append(v)
```

```
[47]: # Jako, że zdefiniowaliśmy już funkcję na znormalizowaną pochodną to możemy jej
      ↪ teraz użyć
      for derivative_order, v in enumerate(polynomials):
          print(f"Derivative value at x_0 = {x_0} of order {derivative_order} equals_
          ↪ {derivative(v, derivative_order, x_0)}, normalized derivative equals_
          ↪ {normalized_derivative(v, x_0)}")
      print(f"(Normalized) Derivatives of order higher than 4 are equal to 0")
```

Derivative value at x_0 = 2 of order 0 equals 13.0, normalized derivative equals 13.0

Derivative value at x_0 = 2 of order 1 equals 23.0, normalized derivative equals 23.0

Derivative value at x_0 = 2 of order 2 equals 36.0, normalized derivative equals 18.0

Derivative value at x_0 = 2 of order 3 equals 42.0, normalized derivative equals 7.0

Derivative value at x_0 = 2 of order 4 equals 24.0, normalized derivative equals 1.0

(Normalized) Derivatives of order higher than 4 are equal to 0

```
[48]: x = sp.symbols('x')
w = x**4 - x**3 + 3*x - 1
w_1 = w.diff(x)
w_1, w_1.subs({x: x_0})
```

```
[48]: (4*x**3 - 3*x**2 + 3, 23)
```

```
[49]: w_2 = w.diff(x, 2)
w_2, w_2.subs({x: x_0})
```

```
[49]: (6*x*(2*x - 1), 36)
```

```
[50]: w_3 = w.diff(x, 3)
w_3, w_3.subs({x: x_0})
```

```
[50]: (6*(4*x - 1), 42)
```

```
[51]: w_4 = w.diff(x, 4)
w_4, w_4.subs({x: x_0})
```

```
[51]: (24, 24)
```

Wygląda na to, że policzyliśmy poprawnie!

2.0.4 Zadanie 4 (* 3 pkt)

Napisz funkcję, która dla danej liczby p ($2 \leq p \leq 9$) i liczby zapisanej w systemie pozycyjnym o podstawie p oblicza jej wartość w systemie dziesiętnym wykorzystując algorytm Hornera. Zakładamy, że dane wejściowe do funkcji są podane w postaci pary (c, p) , gdzie p jest liczbą naturalną z zakresu od 2 do 9, a c jest wektorem kolejnych cyfr w zapisie pozycyjnym danej liczby, przy czym pierwsza współrzędna odpowiada współczynnikowi przy potęgze liczby p o wykładniku 0.

Przetestuj tę funkcję na poniższych przykładach:

1. $([5, 4, 3, 2, 1], 6)$,
2. $([8, 5, 3, 2, 1, 1], 9)$,
3. $([0, 1, 0, 1, 1, 0, 1], 2)$.

Uwaga! Proszę nie używać wbudowanej funkcji `horner` (w `numpy` `np.polynomial.polynomial.polyval`).

```
[52]: def eval_positional_notation(c, p):
      value = c[-1]
      for c_i in reversed(c[:-1]):
          value = value * p + c_i
      return value
```

```
[53]: # 1.
c = np.array([5,4,3,2,1])
p = 6
```

```
eval_positional_notation(c, p)
```

[53]: 1865

```
[54]: eval_positional_notation(c, p) == P.polyval(p, c)
```

[54]: True

```
[55]: # 2.  
c = np.array([8,5,3,2,1,1])  
p = 9  
eval_positional_notation(c, p)
```

[55]: 67364

```
[56]: eval_positional_notation(c, p) == P.polyval(p, c)
```

[56]: True

```
[57]: # 3.  
c = np.array([0,1,0,1,1,0,1])  
p = 2  
eval_positional_notation(c, p)
```

[57]: 90

```
[58]: eval_positional_notation(c, p) == P.polyval(p, c)
```

[58]: True

2.0.5 Zadanie 5 (* 4 pkt)

Napisz funkcję, która korzystając z uogólnionego schematu Hornera dla wektora n różnych punktów $x = [x_0, x_1, \dots, x_{n-1}]$, wektora $b = [b_0, b_1, \dots, b_n]$ współczynników wielomianu w danego w postaci Newtona i wektora punktów $s = [s_1, s_2, \dots, s_k]$ zwraca wektor wartości tego wielomianu interpolacyjnego w punktach s_1, s_2, \dots, s_k .

Przetestuj tę funkcję dla następujących danych: 1. $x = [2, 4, 6, 8, 10]$, $b = [-1, 1, 2, 3, -4, 1]$, $s = [3, 5, 7, 9]$, 2. $x = [0, 0, -1, -1, -1, -2]$, $b = [3, -3, 3, -3, 2, 0, 2]$, $s = [-1, -2, 0, -1.5, -2.75, 5]$.

```
[59]: def generalized_horner_scheme(x, b, s):  
    value = b[-1]  
    for b_i, x_i in zip(reversed(b[:-1]), reversed(x)):  
        value = value * (s - x_i) + b_i  
    return value
```

```
[60]: # 1.  
x = [2, 4, 6, 8, 10]
```



```
b = [-1, 1, 2, 3, -4, 1]
s = np.array([3, 5, 7, 9])

generalized_horner_scheme(x, b, s)
```

[60]: array([172, -82, 184, -134])

```
[61]: # 2.
x = [0, 0, -1, -1, -1, -2]
b = [3, -3, 3, -3, 2, 0, 2]
s = np.array([-1, -2, 0, -1.5, -2.75, 5])

generalized_horner_scheme(x, b, s)
```

[61]: array([9.00000000e+00, 4.10000000e+01, 3.00000000e+00, 1.84687500e+01,
1.80756348e+02, 7.70130000e+04])